



UNIVERSIDAD DE BURGOS  
ESCUELA POLITÉCNICA SUPERIOR  
Grado en Ingeniería Informática



TFG del Grado en Ingeniería  
Informática

Detección de *malware*  
mediante técnicas de  
Inteligencia Artificial  
Documentación Técnica



Presentado por David Cezar Toderas  
en Universidad de Burgos — 7 de julio de 2025  
Tutor: Álvaro Arnaiz González



---

# Índice general

---

<b>Índice general</b>	<b>i</b>
<b>Índice de figuras</b>	<b>iii</b>
<b>Índice de tablas</b>	<b>iv</b>
<b>Apéndice A Plan de Proyecto Software</b>	<b>1</b>
A.1. Introducción . . . . .	1
A.2. Planificación temporal . . . . .	1
A.3. Estudio de viabilidad . . . . .	4
<b>Apéndice B Especificación de Requisitos</b>	<b>9</b>
B.1. Introducción . . . . .	9
B.2. Objetivos generales . . . . .	9
B.3. Catálogo de requisitos . . . . .	10
B.4. Casos de uso . . . . .	12
<b>Apéndice C Especificación de diseño</b>	<b>17</b>
C.1. Introducción . . . . .	17
C.2. Diseño de datos . . . . .	17
C.3. Diseño procedimental . . . . .	20
C.4. Diseño arquitectónico . . . . .	22
<b>Apéndice D Documentación técnica de programación</b>	<b>27</b>
D.1. Introducción . . . . .	27
D.2. Estructura de directorios . . . . .	27
D.3. Manual del programador . . . . .	28

D.4. Compilación, instalación y ejecución del proyecto . . . . .	33
D.5. Pruebas del sistema . . . . .	35
<b>Apéndice E Documentación de usuario</b>	<b>37</b>
E.1. Introducción . . . . .	37
E.2. Requisitos de usuario . . . . .	37
E.3. Instalación . . . . .	38
E.4. Manual del usuario . . . . .	39
<b>Apéndice F Anexo de sostenibilización curricular</b>	<b>47</b>
F.1. Introducción . . . . .	47
F.2. Impacto de la sostenibilidad en el proyecto . . . . .	47
F.3. Competencias de sostenibilidad adquiridas y aplicadas . . . .	49
<b>Bibliografía</b>	<b>51</b>

---

## Índice de figuras

---

B.1. Diagrama de casos de uso de la aplicación de análisis de <i>malware</i> .	16
C.1. Diagrama de secuencia del proceso de analizar una APK. . . . .	21
C.2. Diagrama de secuencia del proceso de entrenamiento del modelo de red neuronal. . . . .	22
C.3. Arquitectura del modelo de red neuronal y los diferentes clasificadores clásicos. . . . .	25
E.1. Página principal de la aplicación antes de un análisis. . . . .	39
E.2. Página de resumen tras realizar un análisis. . . . .	39
E.3. Pestaña de Predicciones con el detalle de cada modelo. . . . .	40
E.4. Pestaña de características: Sección del AndroidManifest. . . . .	41
E.5. Pestaña de características: Sección de análisis de código. . . . .	41
E.6. Pestaña de características: Propiedades del archivo y datos procesados. . . . .	42
E.7. Pestaña de explicaciones: Gráficos de interpretabilidad global del modelo. . . . .	43
E.8. Pestaña de explicaciones: Gráfico de interpretabilidad local para la APK analizado. . . . .	44
E.9. Pestaña de explicaciones: Gráficos de dependencia de SHAP. . .	45
E.10. Pestaña UMAP: Proyección 2D del espacio de <i>embeddings</i> . . . .	46

---

# Índice de tablas

---

A.1. Resumen de los costes totales del proyecto. . . . .	6
A.2. Características de licencias <i>open source</i> . *Solo marcas registradas.	7
A.3. Licencias del software usado en el proyecto . . . . .	8
B.1. CU-1 Analizar una nueva aplicación APK. . . . .	13
B.2. CU-2 Interpretar el resultado de un análisis. . . . .	14
B.3. CU-3 Gestionar el historial de análisis. . . . .	15
C.1. Esquema del <i>dataset</i> propio. . . . .	19
C.2. Esquema del <i>dataset</i> propio. . . . .	20

## Apéndice A

---

# Plan de Proyecto Software

---

### A.1. Introducción

Este apéndice detalla los aspectos de gestión y planificación que han guiado el desarrollo de este Trabajo de Fin de Grado. Se presentará la planificación temporal seguida del estudio de viabilidad económica que estima los costes asociados al proyecto y, finalmente, un análisis de la viabilidad legal en base a las licencias del *software* empleado para determinar la licencia más adecuada para el producto final.

### A.2. Planificación temporal

Para la gestión de este proyecto se ha adoptado un marco de trabajo inspirado en las metodologías ágiles, concretamente en SCRUM. La filosofía ágil, articulada en el Manifiesto Ágil [6], aboga por la colaboración, la flexibilidad ante los cambios y la entrega de valor de forma incremental, en contraposición a los modelos de desarrollo en cascada tradicionales. Aunque SCRUM está diseñado principalmente para la gestión de equipos, sus principios de organización en iteraciones o *sprints*, la revisión continua y la adaptación han sido muy útiles para estructurar el trabajo individual. En este caso, se ha seguido una versión «ligera» de SCRUM, con *sprints* de cuatro semanas, marcados por reuniones periódicas con el tutor para revisar los avances, resolver dudas y planificar los siguientes pasos. Para la gestión del tiempo diario, se han empleado técnicas de productividad como el método Pomodoro (usando aplicaciones como Forest [2]), alternando

bloques de trabajo intenso con descansos para mantener la concentración y evitar la fatiga.

A continuación, se detalla el cronograma del proyecto, dividido en los diferentes *sprints* realizados:

### **Sprint 1 (2 semanas: 2 diciembre - 15 diciembre)**

Este fue el *sprint* inicial y más corto del proyecto, diseñado para asentar las bases y explorar las posibles líneas de investigación. El objetivo era encontrar un tema que combinara tanto el campo de la ciberseguridad como el de la inteligencia artificial. La primera idea que se exploró fue la de utilizar IA para mitigar vulnerabilidades de *hardware*, concretamente, ataques de ejecución especulativa (Spectre y Meltdown). Sin embargo, tras investigar acerca de ello en la literatura, se concluyó que era un campo extremadamente complejo y con muy poca documentación accesible, por lo que se descartó por su alta incertidumbre.

La investigación continuó pues hacia el análisis de *malware*. Como primer concepto, se consideró la idea de crear un analizador dinámico, una especie de *sandbox* donde ejecutar aplicaciones de forma aislada para estudiar su comportamiento en tiempo real. Aunque este enfoque contaba con más documentación, se determinó que la complejidad de desarrollar un entorno de este tipo desde cero era demasiado ambiciosa para el alcance del trabajo. Este *sprint* fue el más breve y acabó antes de tiempo debido, principalmente a su proximidad con los exámenes finales y a las vacaciones de Navidad.

### **Sprint 2 (4 semanas: 20 enero - 16 febrero)**

Tras las vacaciones, se retomó la investigación centrándose en el análisis de *malware*, pero esta vez explorando otras técnicas como el análisis estático y el híbrido. El análisis estático destacó inmediatamente por su principal ventaja: la capacidad de detectar *malware* sin ejecutarlo. La literatura confirmó que la combinación de análisis estático y modelos de aprendizaje profundo *deep learning* era un campo de investigación muy activo y con resultados prometedores.

Con esta idea clara, se procedió a elegir la plataforma. Se descartaron los ejecutables de Windows (PE) y Linux (ELF) por la dificultad de analizar código máquina compilado. La elección final fue el formato APK de Android, ya que su estructura, similar a un archivo comprimido, y su código Dalvik, fácilmente descompilable, simplificaban enormemente la extracción de características. Durante este *sprint* se encontraron los *papers* fundamentales



que servirían de guía para el resto del proyecto, especialmente el trabajo de İbrahim et al. [8], que se convirtió en la principal referencia de este.

### **Sprint 3 (4 semanas: 17 febrero - 16 marzo)**

Con el rumbo del proyecto ya definido, este *sprint* se centró en comenzar la fase de prototipado. El primer paso fue buscar un *dataset* adecuado para las pruebas iniciales. Tras evaluar varias opciones, se seleccionó el *dataset* Drebin [5] por su gran tamaño y la similitud de sus características con las descritas en el *paper* de referencia. Se dedicó una parte importante del tiempo a desarrollar los *scripts* necesarios para procesar el formato particular de Drebin y convertirlo en un archivo CSV manejable. Paralelamente, se comenzó a redactar la memoria del proyecto, documentando los primeros conceptos teóricos de ciberseguridad, y se integró la herramienta Poetry para facilitar con la gestión de dependencias.

### **Sprint 4 (4 semanas: 17 marzo - 13 abril)**

Este *sprint* fue de carácter principalmente teórico y de diseño. A medida que avanzaba la investigación sobre cómo construir una red neuronal desde cero, se fue ampliando la sección de conceptos de la memoria con las definiciones de IA, aprendizaje automático, preprocesamiento de datos, etc. Se estudió en profundidad el funcionamiento de las redes neuronales, las funciones de pérdida, los optimizadores y las arquitecturas de *embedding*. El objetivo era adquirir toda la base teórica necesaria antes de empezar a escribir el código del modelo prototipo.

### **Sprint 5 (4 semanas: 14 abril - 11 mayo)**

Durante este *sprint* se desarrolló la primera versión del modelo de red neuronal en PyTorch, basado en el *dataset* Drebin. Durante este proceso surgió el dilema del *embedder*: se tomó la decisión clave de separar la arquitectura en un *embedder* (preprocesador) y una cabeza clasificadora (MLP) para poder comparar el modelo con algoritmos clásicos de ML. Se implementó el proceso de entrenamiento para la red neuronal y para los modelos clásicos, se unificó el sistema de guardado y carga de modelos, y se generaron las primeras gráficas y estadísticas de rendimiento, que validaron la viabilidad del enfoque.

### **Sprint 6 (4 semanas: 12 mayo - 8 junio)**

Con el prototipo validado, este *sprint* se dedicó a refinar el código y a preparar la transición hacia el modelo final. Se refactorizó la implementación actual del modelo para separarlo en componentes más modulares y fáciles de mantener y modificar. El proceso de entrenamiento se mejoró para incluir la estratificación de los datos y tener en cuenta el desbalance de clases. Al mismo tiempo, comenzó la creación del *dataset* propio, se realizaron pruebas con Androguard para la extracción de características y se descubrió el repositorio AndroZoo [4], con el que se experimentó para automatizar la descarga de APKs. Finalmente, se desarrolló el *pipeline* completo para la creación del nuevo *dataset* y se adaptó el código del modelo para que fuera compatible con el.

### **Sprint 7 (4 semanas: 9 junio - 6 julio)**

Este fue el *sprint* final y más intenso. La adaptación del modelo al nuevo y mucho más complejo *dataset* reveló graves problemas de rendimiento y diseño que habían pasado desapercibidos. Se dedicó un gran esfuerzo a la depuración y optimización del modelo, solucionando problemas de gestión de memoria, cuellos de botella en el procesamiento de datos y la inhabilidad del modelo para entrenar. Una vez solucionados, se reentrenó el modelo final y se realizó el análisis de resultados comparativo y de interpretabilidad. Paralelamente, se desarrolló la aplicación web de demostración con Streamlit, se creó el repositorio de despliegue con Docker y se desplegó la aplicación en un servidor de la universidad. Finalmente, se terminó de redactar toda la documentación del proyecto; la memoria y sus anexos.

## **A.3. Estudio de viabilidad**

En este apartado se realiza un análisis de la viabilidad del proyecto desde dos perspectivas: la económica, estimando los costes asociados a su desarrollo, y la legal, estudiando las licencias del software utilizado para determinar la licencia más apropiada para el trabajo resultante.

### **Viabilidad económica**

A continuación, se calcularán los costes teóricos asociados al desarrollo de este proyecto, considerando un escenario profesional hipotético en el que se contratara a personal y se adquirieran los recursos necesarios. Se desglosarán los costes en personales, de hardware, de software e indirectos.

### Costes de personal

Son los costes asociados al salario de las personas que han trabajado en el proyecto. Se estima una dedicación de unas 650 horas a lo largo de 6 meses, lo que equivale a unas 28 horas semanales. Tomando como referencia el salario medio de un ingeniero júnior en España (aproximadamente 1 930 € brutos/mes por 40 horas semanales), el salario proporcional sería:

$$\frac{28 \text{ h/semana}}{40 \text{ h/semana}} \times 1\,930 \text{ €/mes} = 1\,351 \text{ €/mes}$$

A este salario hay que sumarle las cotizaciones a la Seguridad Social a cargo de la empresa. Según las bases de cotización vigentes [3], los tipos aplicables para contingencias comunes y profesionales suman aproximadamente un 30.57 % (23.6 % por contingencias comunes, 5.5 % por desempleo, 0.2 % FOGASA (FONdo de GARantía SALarial), 0.6 % por formación profesional y 0.67 por MEI (Mecanismo de Equidad Intergeneracional)). Por tanto, el coste total del desarrollador para la empresa durante los 6 meses sería:

$$1\,351 \text{ €} \times (1 + 0.3057) \times 6 \text{ meses} = 10\,584 \text{ €}$$

Adicionalmente, se estima el coste del tutor del proyecto, con una dedicación de 1 hora semanal (4 horas/mes) y una tarifa supuesta de 30 €/hora.

$$(30 \text{ €/h} \times 4 \text{ h/mes}) \times (1 + 0.3057) \times 6 \text{ meses} = 940.10 \text{ €}$$

Por tanto, el coste total en personal es de 11 524.10 €.

### Costes de *hardware* (materiales)

El proyecto se desarrolló en un ordenador personal valorado en 1 600 €. Suponiendo una vida útil de 5 años, el coste de amortización para los 6 meses de proyecto es:

$$\frac{1\,600 \text{ €}}{5 \text{ años}} \times \frac{6 \text{ meses}}{12 \text{ meses/año}} = 160 \text{ €}$$

Además, para el entrenamiento del modelo se podría haber utilizado un servicio de *cloud computing*. Una estimación para una instancia pequeña durante un supuesto de 150 horas de trabajo en Google Cloud Platform sería de aproximadamente 108.65 €. Por lo cual, el coste total de *hardware* sería de 268.65 €.

### Costes de *software*

Todo el *software* empleado en el desarrollo del proyecto es de código abierto y gratuito, con la única posible excepción del sistema operativo. Asumiendo el uso de una licencia de Windows 11 Home, y, que esta licencia no se usaría únicamente en este proyecto sino que se amortizaría de forma similar al ordenador, los costes de software serían:

$$\frac{145 \text{ €}}{5 \text{ años}} \times \frac{6 \text{ meses}}{12 \text{ meses/año}} = 14.50 \text{ €}$$

### Costes indirectos

Estos costes incluyen los suministros necesarios para el desarrollo. Suponiendo un consumo eléctrico medio de 50 kWh/mes a un precio de 0.1702 €/kWh y un coste de conexión a *internet* de 30 €/mes, los costes indirectos para los 6 meses de proyecto serían de 231.06 €:

$$(50 \text{ kWh/mes} \times 0.1702 \text{ €/kWh} \times 6 \text{ meses}) + \\ (30 \text{ €/mes} \times 6 \text{ meses}) = 51.06 \text{ €} + 180 \text{ €} = 231.06 \text{ €}$$

### Coste total del proyecto

La suma de todas los costes anteriores nos da una estimación del coste total teórico del proyecto.

Concepto	Coste Estimado
Costes de personal	11 524.10 €
Costes de hardware	268.65 €
Coste de software	14.50 €
Costes indirectos	231.06 €
<b>Coste total</b>	<b>12 038.31 €</b>

Tabla A.1: Resumen de los costes totales del proyecto.

Dado que el proyecto es de carácter puramente académico y de investigación, no se contempla la posibilidad de comercializarlo, por lo cual, no se calculan los posibles beneficios de este.

## Viabilidad legal

Este apartado analiza las licencias del software utilizado para determinar bajo qué licencia puede ser distribuido este proyecto, garantizando el cumplimiento de todos los términos legales.

### Tipos de licencias *Open Source*

Existen numerosas licencias de código abierto, cada una con diferentes permisos y obligaciones. La siguiente tabla resume algunas de las más comunes.

	MIT	BSD-2	BSD-3	Apache 2.0	LGPL-2.1	GPL-3.0
<b>Permisos</b>						
Uso comercial	✓	✓	✓	✓	✓	✓
Modificación	✓	✓	✓	✓	✓	✓
Distribución	✓	✓	✓	✓	✓	✓
Uso privado	✓	✓	✓	✓	✓	✓
Patentes concedidas				✓		(implícitas)
<b>Condiciones</b>						
Conservar aviso/licencia	✓	✓	✓	✓	✓	✓
Indicar cambios				✓	✓	✓
Publicar código derivado					(solo lib)	✓
Misma licencia en derivado					(solo lib)	✓
No uso del nombre/marca			✓	✓*		
<b>Limitaciones</b>						
Sin garantía	✓	✓	✓	✓	✓	✓
Sin responsabilidad	✓	✓	✓	✓	✓	✓

Tabla A.2: Características de licencias *open source*. \*Solo marcas registradas.

### Licencias del software empleado

La gran mayoría de las herramientas y librerías utilizadas en este proyecto se distribuyen bajo licencias de código abierto muy permisivas.

### Elección de la licencia del proyecto

Como se muestra en la tabla A.3, la mayoría de las dependencias utilizan licencias permisivas como MIT, BSD y Apache 2.0, que permiten el uso, modificación y distribución del software con muy pocas restricciones. El único caso especial es Androguard, licenciado bajo LGPLv2.1. Esta licencia

Software / Herramienta	Licencia
Python	PSF License (similar a BSD)
Poetry, Optuna, SHAP	MIT License
Conda, Jupyter, PyTorch, Scikit-learn, NumPy, Pandas, UMAP	BSD 3-Clause License (o similar)
Matplotlib	PSF/BSD-style License
Streamlit, Docker	Apache License 2.0
Androguard	GNU Lesser General Public License v2.1 (LGPLv2.1)

Tabla A.3: Licencias del software usado en el proyecto

exige que si se modifica el código fuente de la librería, dichas modificaciones deben publicarse bajo la misma licencia. Sin embargo, como este proyecto utiliza Androguard como una librería externa, sin modificar su código, no estamos obligados a aplicar la licencia LGPL a nuestro propio código.

Dada la naturaleza permisiva de las licencias de las dependencias, la opción más adecuada para este proyecto es una licencia igualmente permisiva. Por tanto, se ha decidido licenciar este trabajo bajo la licencia MIT, ya que maximiza la libertad de uso y es compatible con el resto del ecosistema de herramientas.

### Legalidad del análisis de aplicaciones

Un punto importante a considerar es la legalidad de desensamblar y analizar archivos APK. La legislación europea, concretamente la Directiva 2009/24/CE sobre la protección jurídica de los programas de ordenador [7], contempla excepciones al derecho exclusivo del autor. El artículo 6 permite la descompilación cuando sea indispensable para obtener la información necesaria para lograr la interoperabilidad de un programa creado de forma independiente. Aunque el fin de este proyecto es la seguridad, el principio es análogo: se analiza la aplicación para entender su funcionamiento e interoperabilidad con el sistema operativo con fines de investigación y defensa. Es crucial destacar que este proyecto no modifica ni redistribuye ninguna de las aplicaciones analizadas; únicamente extrae características de ellas para su estudio, una práctica ampliamente aceptada y considerada legítima.

## Apéndice *B*

---

# Especificación de Requisitos

---

### B.1. Introducción

Este apéndice documenta la especificación de requisitos del trabajo desarrollado. Su propósito es definir de manera formal y detallada las capacidades, características y restricciones del sistema. Se establecen los objetivos generales del proyecto, se desglosa un catálogo de requisitos funcionales y no funcionales, y finalmente, se describen los principales casos de uso que ilustran la interacción del usuario con la aplicación.

### B.2. Objetivos generales

Los objetivos generales representan las metas de alto nivel que se buscaron alcanzar con la realización de este trabajo, combinando tanto las aspiraciones de investigación como los entregables prácticos.

1. **Investigar el estado del arte:** Realizar un análisis de la literatura científica para comprender las técnicas actuales de detección de *malware* con IA y posicionar el proyecto en el panorama actual.
2. **Desarrollar un sistema de detección de extremo a extremo:** Construir un *pipeline* completo, desde la recolección de datos y la extracción de características hasta el entrenamiento y la evaluación de un modelo funcional.

3. **Alcanzar un alto rendimiento predictivo:** Lograr que los modelos desarrollados obtengan métricas de clasificación altas, con un enfoque especial maximizar el *recall* para minimizar los falsos negativos.
4. **Comparar diferentes arquitecturas de modelos:** Evaluar y contrastar el rendimiento de una red neuronal profunda frente a algoritmos de aprendizaje automático clásicos para obtener conclusiones sobre la eficacia de cada enfoque.
5. **Garantizar la interpretabilidad del sistema:** Implementar técnicas que permitan explicar las decisiones de los modelos, aportando transparencia y confianza a los resultados.
6. **Crear una aplicación de demostración:** Desarrollar una interfaz web interactiva que permita a un usuario probar y visualizar el funcionamiento de todo el sistema.

### B.3. Catálogo de requisitos

A continuación se presenta el catálogo detallado de requisitos que el sistema debe satisfacer.

#### Requisitos funcionales

Los requisitos funcionales (RF) especifican lo que el sistema debe hacer. Describen las funcionalidades, tareas y servicios que la aplicación final debe proporcionar al usuario para cumplir con su propósito.

- **RF-1: Carga de archivos APK.** El sistema debe proporcionar una interfaz que permita al usuario seleccionar y subir un archivo con formato `.apk` para su posterior análisis.
- **RF-2: Análisis y clasificación de la aplicación.** Una vez subida una APK, el sistema debe ejecutar el *pipeline* de análisis completo. Esto incluye la extracción de características estáticas, el preprocesamiento de los datos a través del *embedder* y la ejecución de la inferencia con todos los modelos entrenados (la red neuronal y los clasificadores clásicos).
- **RF-3: Visualización de las predicciones.** La aplicación debe presentar al usuario los resultados de la clasificación de forma clara. Debe mostrar un veredicto general y una tabla detallada con la predicción



de cada modelo individual, incluyendo los porcentajes de confianza para las clases «benigno» y «malicioso».

- **RF-3.1: Transparencia del proceso de extracción.** Para que el proceso no sea una «caja negra», la interfaz debe permitir al usuario inspeccionar las características «brutas» que han sido extraídas de la APK. Esto incluye las diferentes listas de permisos, actividades, servicios, receptores, así como propiedades del archivo como su tamaño o su *fuzzy hash*.
  - **RF-3.2: Visualización de datos procesados.** Además de los datos en «bruto», el sistema debe mostrar la representación numérica en la que se transforman. Esto implica visualizar tanto los datos *tokenizados* y escalados como el vector de *embeddings* final que se introduce en los clasificadores.
- 
- **RF-4: Interpretabilidad de las predicciones.** La aplicación debe ofrecer explicaciones sobre las decisiones del modelo. Para ello, deberá generar y mostrar un conjunto de gráficos de SHAP, incluyendo la importancia global de las características y análisis locales que detallen qué factores han influido en la predicción de la muestra actual.
  - **RF-5: Visualización del espacio de características.** El sistema debe ser capaz de generar una proyección 2D del espacio de *embeddings* mediante UMAP. En esta visualización, se debe mostrar la distribución de las muestras del *dataset* de fondo y resaltar la posición de la APK recién analizada, permitiendo al usuario entender su ubicación relativa respecto a las clases conocidas.
  - **RF-6: Gestión del historial de análisis.** El sistema debe mantener un historial de las aplicaciones analizadas durante la sesión activa del usuario. La interfaz debe permitir al usuario seleccionar una entrada del historial para volver a cargar sus resultados y ofrecer una opción para borrar todo el historial de la sesión.

## Requisitos no funcionales

Los requisitos no funcionales (RNF) describen los atributos de calidad y las restricciones bajo las cuales el sistema debe operar. No se refieren a qué hace el sistema, sino a «cómo» lo hace, definiendo aspectos como su rendimiento, fiabilidad o portabilidad.

- **RNF-1: Rendimiento y fiabilidad de los modelos.** Los distintos clasificadores deben alcanzar un alto nivel de rendimiento, definido por métricas de evaluación estándar. Específicamente, se establece como requisito clave obtener una métrica de *recall* cercana al 98 %, garantizando una detección muy alta de las muestras maliciosas.
- **RNF-2: Eficiencia del análisis.** El tiempo total desde que el usuario sube una APK hasta que recibe un resultado completo (incluyendo la extracción, el preprocesamiento y la inferencia) debe ser razonable para una buena experiencia de usuario, idealmente completándose en menos de un par de minutos.
- **RNF-3: Portabilidad y facilidad de despliegue.** Todo el sistema, incluyendo la aplicación web, el modelo y sus dependencias, debe estar empaquetado en un contenedor Docker. Esto asegura que la aplicación sea portable y pueda ser desplegada de forma sencilla y consistente en diferentes sistemas operativos.
- **RNF-4: Usabilidad de la interfaz.** La aplicación web debe tener una interfaz de usuario clara, intuitiva y fácil de navegar para un perfil de usuario con conocimientos técnicos, pero no necesariamente experto en inteligencia artificial. La información debe presentarse de forma organizada y comprensible.
- **RNF-5: Modularidad del código.** La base de código del proyecto debe seguir un diseño modular que separe claramente las distintas responsabilidades (extracción de datos, arquitectura del modelo, entrenamiento, etc.). Esto facilita el mantenimiento, la experimentación y el posible desarrollo futuro del sistema.

## B.4. Casos de uso

Los casos de uso describen las interacciones entre un actor (en este caso, el «Usuario/Analista») y el sistema para alcanzar un objetivo. A continuación se presenta un diagrama esquemático (Figura B.1) y se detallan los tres casos de uso principales.

CU-1	Analizar una nueva aplicación APK
<b>Versión</b>	1.0
<b>Autor</b>	David Cezar Toderas
<b>Requisitos asociados</b>	RF-1, RF-2, RF-3
<b>Descripción</b>	El usuario sube un archivo APK al sistema para que este sea analizado por los modelos de IA y se muestren los resultados de la clasificación.
<b>Precondición</b>	El usuario tiene un archivo <code>.apk</code> válido y la aplicación web está en ejecución.
<b>Acciones</b>	<ol style="list-style-type: none"> <li>1. El usuario accede a la aplicación web.</li> <li>2. El usuario arrastra y suelta un archivo APK en la zona de carga o lo selecciona mediante el explorador de archivos.</li> <li>3. El usuario presiona el botón «Analizar APK».</li> <li>4. El sistema procesa el archivo: extrae las características, las pasa por el <i>embedder</i> y realiza la inferencia con todos los modelos.</li> <li>5. La interfaz se actualiza para mostrar la pestaña de «Predicciones» con el veredicto de cada modelo.</li> <li>6. El análisis se añade al historial de la sesión.</li> </ol>
<b>Postcondición</b>	Se muestra una predicción de clasificación para la APK subida.
<b>Excepciones</b>	<p><b>E-1.1:</b> Si el archivo subido no es un APK válido, el sistema muestra un mensaje de error.</p> <p><b>E-1.2:</b> Si el archivo supera el límite de tamaño, el sistema muestra una advertencia y no permite el análisis.</p>
<b>Importancia</b>	Alta

Tabla B.1: CU-1 Analizar una nueva aplicación APK.

CU-2	Interpretar el resultado de un análisis
<b>Versión</b>	1.0
<b>Autor</b>	David Cezar Toderas
<b>Requisitos asociados</b>	RF-3.1, RF-3.2, RF-4, RF-5
<b>Descripción</b>	Tras analizar un APK, el usuario explora las diferentes pestañas de la interfaz para comprender en profundidad el resultado y el razonamiento del modelo.
<b>Precondición</b>	Se ha completado con éxito un análisis (CU-1).
<b>Acciones</b>	<ol style="list-style-type: none"> <li>1. El usuario navega a la pestaña «Características Extraídas» para ver los datos brutos y procesados.</li> <li>2. El usuario navega a la pestaña «Explicaciones» para visualizar los gráficos de importancia de características de SHAP.</li> <li>3. El usuario navega a la pestaña «UMAP» para ver la proyección del <i>embedding</i> de la aplicación analizada.</li> </ol>
<b>Postcondición</b>	El usuario obtiene una visión detallada de los datos y las justificaciones que respaldan la predicción del modelo.
<b>Excepciones</b>	Ninguna.
<b>Importancia</b>	Alta

Tabla B.2: CU-2 Interpretar el resultado de un análisis.

CU-3	Gestionar el historial de análisis
<b>Versión</b>	1.0
<b>Autor</b>	David Cezar Toderas
<b>Requisitos asociados</b>	RF-6
<b>Descripción</b>	El usuario interactúa con el historial de análisis de la sesión actual para consultar resultados anteriores o para limpiar la lista.
<b>Precondición</b>	Se ha analizado al menos una aplicación durante la sesión actual.
<b>Acciones</b>	<p><b>Flujo A: Consultar un análisis anterior</b></p> <ol style="list-style-type: none"> <li>1. El usuario hace clic sobre el nombre de un archivo en la lista del «Historial de Análisis».</li> <li>2. El sistema carga en la vista principal todos los datos y resultados correspondientes a ese análisis.</li> </ol> <p><b>Flujo B: Limpiar el historial</b></p> <ol style="list-style-type: none"> <li>1. El usuario hace clic en el botón «Limpiar Historial».</li> <li>2. El sistema borra todas las entradas del historial de la sesión.</li> </ol>
<b>Postcondición</b>	<p><b>Flujo A:</b> La interfaz muestra los resultados del análisis seleccionado.</p> <p><b>Flujo B:</b> La lista del historial de análisis queda vacía.</p>
<b>Excepciones</b>	Ninguna.
<b>Importancia</b>	Media

Tabla B.3: CU-3 Gestionar el historial de análisis.

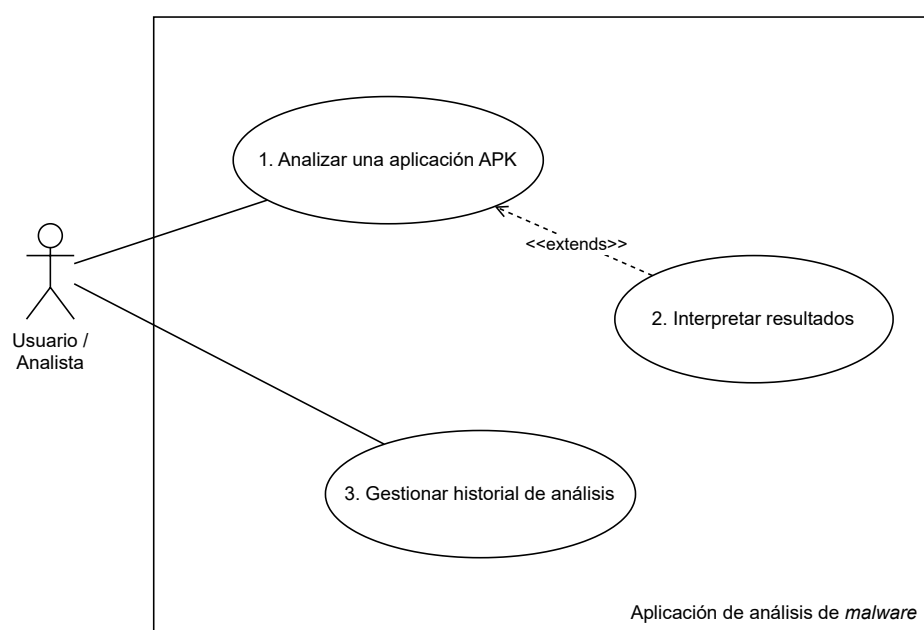


Figura B.1: Diagrama de casos de uso de la aplicación de análisis de *malware*.

## Apéndice C

---

# Especificación de diseño

---

### C.1. Introducción

Este apéndice presenta el diseño técnico detallado del sistema desarrollado. Su objetivo es servir como un plano que describe la arquitectura del software, la estructura de los datos con los que opera y la lógica procedimental de sus operaciones clave. Se abordará el diseño desde tres perspectivas: el diseño de datos, que define la estructura de los archivos APK y los *datasets*; el diseño procedimental, que ilustra las interacciones principales mediante diagramas de secuencia; y el diseño arquitectónico, que desglosa la estructura interna del modelo de inteligencia artificial y de la aplicación web.

Este apéndice detalla el diseño técnico del sistema desarrollado, abarcando tres áreas fundamentales: el diseño de los datos, el diseño procedimental y el diseño arquitectónico. El objetivo es proporcionar una descripción clara y estructurada de cómo se ha organizado la información, cómo fluyen los procesos lógicos y cómo se ha construido la arquitectura del software, desde el modelo de inteligencia artificial hasta la aplicación web.

### C.2. Diseño de datos

El diseño de datos es fundamental para cualquier sistema de aprendizaje automático. En esta sección se describe la estructura de los datos de entrada (archivos APK), el formato de los *datasets* utilizados durante el desarrollo y el *pipeline* de preprocesamiento que los transforma para que puedan ser consumidos por los modelos.

## Estructura de un archivo APK

Un archivo APK (*Android Package Kit*) es el formato de paquete utilizado por el sistema operativo Android para la distribución e instalación de aplicaciones móviles. Aunque parece un único archivo, en realidad es un archivo comprimido (basado en el formato JAR y, por tanto, compatible con ZIP) que contiene un conjunto de ficheros y directorios con una estructura bien definida. La estructura de una APK es la siguiente:

```
/
├── assets
├── lib
│   ├── arm64-v8a
│   ├── x86
│   ├── x86_64
│   └── ...
├── META-INF
│   ├── CERT.SF
│   ├── CERT.RSA
│   └── MANIFEST.MF
├── kotlin
├── res
├── AndroidManifest.xml
├── classes.dex
└── resources.arsc
```

Los componentes más relevantes son:

- **assets/**: Contiene recursos brutos que la aplicación puede utilizar, como ficheros de configuración, bases de datos o recursos de *machine learning*.
- **lib/**: Como Android es multiplataforma, este directorio incluye el código compilado específico de las diferentes arquitecturas de procesador (ARM, x86). Contiene, a su vez, las librerías nativas de la aplicación.
- **META-INF/**: Almacena los metadatos de la firma de la aplicación. Los ficheros **CERT.SF** y **CERT.RSA** contienen el certificado y la firma que garantizan la autenticidad e integridad de la aplicación, mientras que **MANIFEST.MF** contiene los *hashes* de todos los ficheros del paquete.
- **kotlin**: Directorio que contiene el código fuente de Kotlin, si la aplicación está escrita en este lenguaje.



- **res/**: Contiene los recursos de la aplicación que no están compilados, como los diseños de la interfaz (*layouts*), las imágenes (*drawables*) o las cadenas de texto (*strings*).
- **AndroidManifest.xml**: Es el archivo más importante del APK. Es un fichero XML obligatorio que describe la información esencial sobre la aplicación al sistema Android, como su nombre, componentes (actividades, servicios), permisos, versiones SDK mínima y objetivo.
- **classes.dex**: Contiene el código de la aplicación compilado en formato DEX (*Dalvik Executable*), que es el que ejecuta la máquina virtual de Android (ART / Dalvik). Puede haber múltiples archivos .dex si la aplicación es grande.
- **resources.arsc**: Es un archivo que contiene recursos precompilados, como las cadenas de texto, para un acceso más eficiente por parte del sistema.

## Diseño de los conjuntos de datos

A lo largo del proyecto se han utilizado dos *datasets* principales: el *dataset* público Drebin para la fase de prototipado y un *dataset* propio para el desarrollo del modelo final.

### Dataset Drebin

El formato original del *dataset* Drebin no era una tabla, sino una estructura de directorios compleja. Tras un proceso de *parsing*, se transformó en un único archivo CSV con la siguiente estructura por fila:

sha256	req_permissions	app_components	...	malware
000a06	"com.android.permission..., ..."	"com.android..., ..."	...	0

Tabla C.1: Esquema del *dataset* propio.

Cada fila representa una aplicación, identificada por su *hash* SHA256, y cada columna contiene una lista de las características estáticas extraídas de la misma.

### Dataset propio

El *dataset* final se construyó desde cero extrayendo características de 20 000 APKs obtenidas de AndroZoo. El formato resultante es un único fichero CSV donde cada fila corresponde a una aplicación. La estructura es la siguiente:

file_size	fuzzy_hash	activities_list	...	opcode_counts	is_malware
321245	"ab34cd56"	["com.android...", ...]	...	[221, 3455, 3467, ...]	0

Tabla C.2: Esquema del *dataset* propio.

### Pipeline de preprocesado de datos

Para que los datos de los *datasets* puedan ser utilizados por los modelos, necesitan pasar primero por un *pipeline* de preprocesamiento dividido en dos fases:

1. **Procesamiento externo (offline):** Antes de iniciar cualquier entrenamiento, se realizan una serie de pasos sobre el *dataset* completo. Para cada característica categórica (como los permisos o las actividades), se construye un vocabulario que asigna un índice numérico único a cada posible valor. Luego, todas las listas de cadenas de texto se convierten en listas de índices. Finalmente, se aplica un *padding* para que todas las listas de una misma columna tengan la misma longitud, convirtiéndolas en matrices numéricas.
2. **Procesamiento interno (online):** Una vez los datos están en formato de matrices de índices, el *embedder* del modelo se encarga del resto. Durante el entrenamiento o la inferencia, aplica las capas de *embedding* para convertir estos índices en vectores densos. Además, las características numéricas escalares (como el `file_size`) son normalizadas internamente por el modelo para que sus rangos de valores no desestabilicen el entrenamiento.

## C.3. Diseño procedimental

Para ilustrar el flujo de trabajo y las interacciones dentro del sistema, a continuación se presentan los diagramas de secuencia de los dos procesos más importantes: el análisis de un APK por parte de un usuario y el proceso interno de entrenamiento de un modelo.

**Diagrama de secuencia: Análisis de un nuevo archivo APK**

Este diagrama muestra la secuencia de interacciones desde que un usuario sube un archivo a la aplicación web hasta que recibe una predicción.

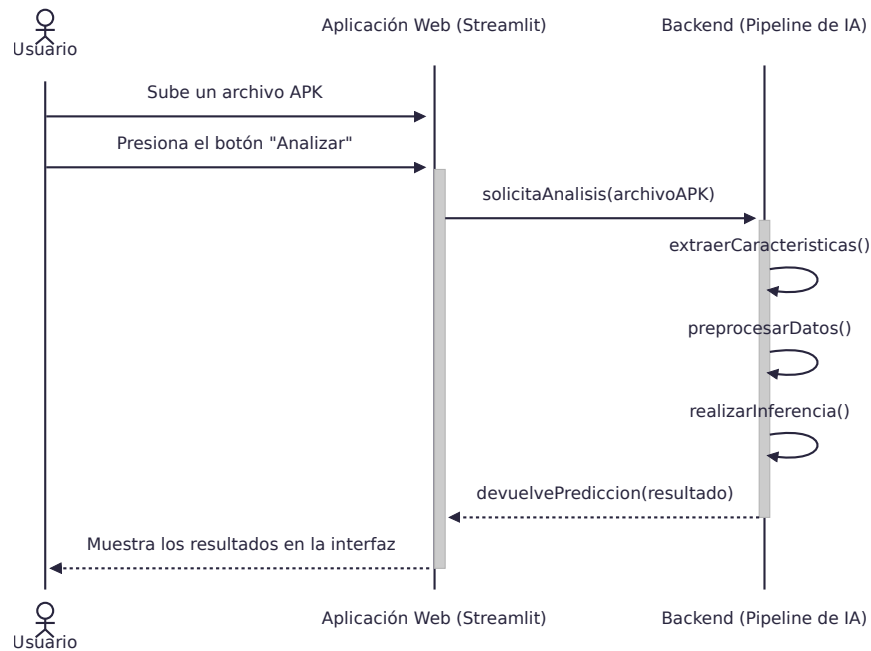


Figura C.1: Diagrama de secuencia del proceso de analizar una APK.

**Diagrama de secuencia: Proceso de entrenamiento del modelo**

Este diagrama detalla el bucle de entrenamiento de la red neuronal, un proceso iniciado por el desarrollador para ajustar los pesos del modelo.

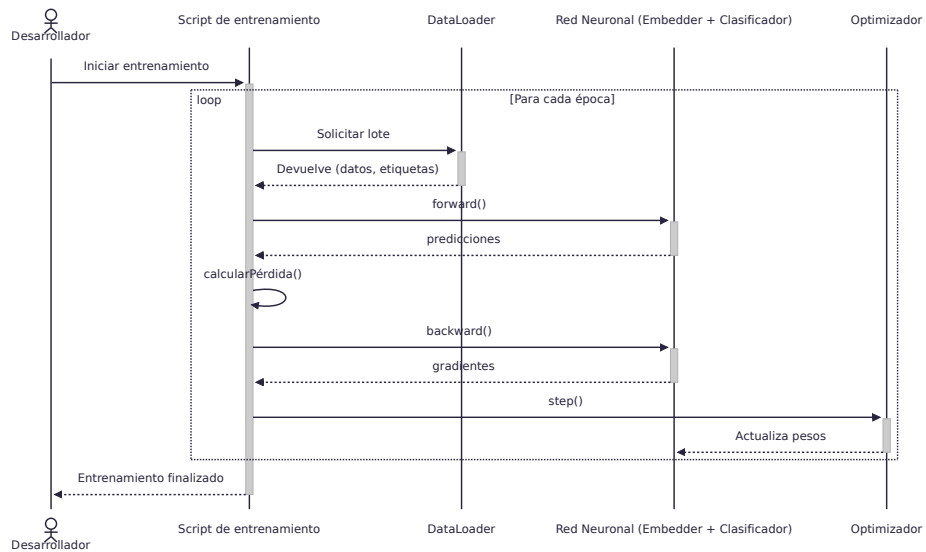


Figura C.2: Diagrama de secuencia del proceso de entrenamiento del modelo de red neuronal.

## C.4. Diseño arquitectónico

En esta sección se detalla la arquitectura tanto del modelo de inteligencia artificial como de la aplicación web de demostración.

### Arquitectura del modelo

En esta sección se detalla la arquitectura del software, tanto del modelo de inteligencia artificial como de la aplicación web que lo utiliza.

### Arquitectura del modelo

El modelo de inteligencia artificial, implementado en PyTorch, sigue una arquitectura modular y flexible, compuesta por dos grandes bloques: el *embedder* y el clasificador.

```

APKAnalysisModel(
    (embedder): APKFeatureEmbedder(
        (seq_embedders): ModuleDict(...)
        (char_embedders): ModuleDict(...)
        (char_gru): ModuleDict(...)
        (vector_reducers): ModuleDict(...)
    )
    (classifier): APKClassifier(
        (mlp): Sequential(...)
    )
)

```

- **APKFeatureEmbedder (Embedder):** Es el componente más complejo y el corazón del sistema. Su única responsabilidad es recibir las características preprocesadas de un APK y convertirlas en un único vector numérico denso. Para ello, contiene diferentes submódulos especializados:
  - **seq\_embedders:** Un diccionario de capas ‘Embedding’ de PyTorch, una para cada característica de tipo lista (permisos, actividades, etc.). Cada capa aprende a representar los elementos de su vocabulario como un vector.
  - **char\_embedders y char\_gru:** Un módulo especializado para procesar el FUZZY\_HASH. Trata el *hash* como una secuencia de caracteres, los convierte en vectores con un *embedding* y luego los procesa con una capa GRU (Gated Recurrent Unit) para capturar patrones secuenciales.
  - **vector\_reducers:** Un diccionario de pequeñas redes neuronales (MLPs) que toman las características que ya son vectores numéricos (como OPCODE\_COUNTS) y reducen su dimensionalidad para que sea consistente con la de los otros *embeddings*.

La salida de todos estos submódulos, junto con las características escalares, se concatena para formar el vector final.

- **APKClassifier (Clasificador):** Este componente es la cabeza del modelo. Por defecto, es una red neuronal de tipo Perceptrón Multicapa (MLP) que toma el vector del *embedder* y, a través de una o más capas ocultas con funciones de activación ReLU y capas de *dropout*, lo procesa para obtener la predicción final en sus dos neuronas de salida.

Una de las claves de este diseño es que la cabeza clasificadora es intercambiable. La salida del *embedder* es un vector de características de alta calidad que puede ser utilizado para entrenar cualquier otro modelo de aprendizaje automático clásico (como RandomForest, XGBoost, SVM, etc.), tratando a la red neuronal simplemente como un potente paso de ingeniería de características. Una representación de la arquitectura completa del modelo puede verse en la figura C.3.

## Arquitectura de la aplicación web

La aplicación de demostración se ha desarrollado con Streamlit y sigue una arquitectura cliente-servidor simple.

- **Cliente:** Es el navegador web del usuario. Se encarga de renderizar la interfaz de usuario y de enviar las interacciones del usuario (como la subida de un archivo o el clic en un botón) al servidor.
- **Servidor:** Es el *script* de Python de Streamlit que se ejecuta en el servidor. Este se encarga de toda la lógica de la aplicación: recibe las peticiones del cliente, carga los modelos de IA de los artefactos guardados, ejecuta el *pipeline* de análisis sobre los datos recibidos y genera dinámicamente los componentes de la interfaz (tablas, gráficos, texto) que se envían de vuelta al cliente para ser mostrados.

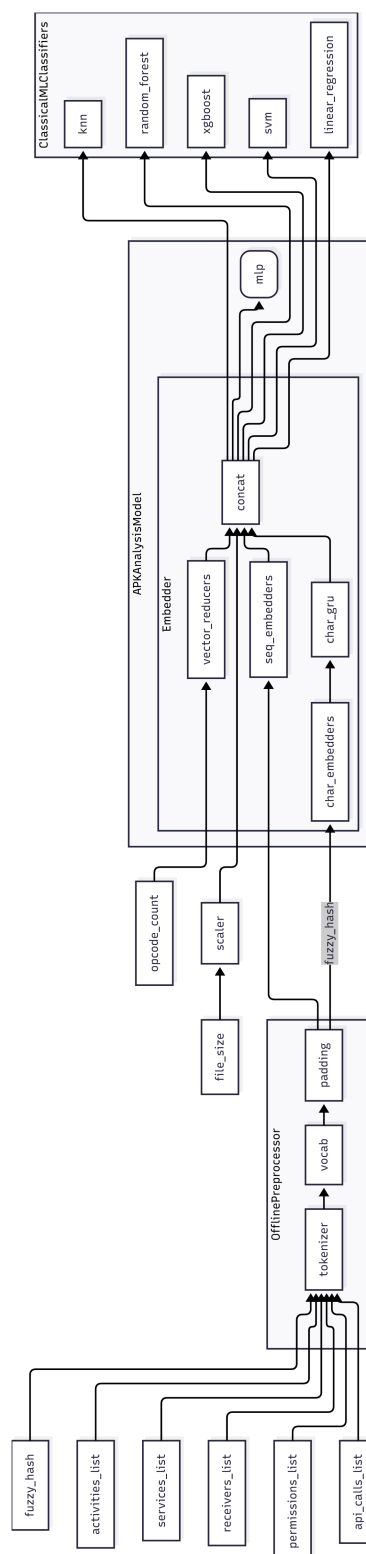


Figura C.3: Arquitectura del modelo de red neuronal y los diferentes clasificadores clásicos.





## Apéndice *D*

---

# Documentación técnica de programación

---

### D.1. Introducción

Este apéndice sirve como manual técnico y guía para cualquier desarrollador que desee comprender, extender o contribuir a este proyecto. El objetivo es proporcionar toda la información necesaria para configurar el entorno de desarrollo, entender la estructura del código fuente, y ejecutar los procesos clave como la creación del *dataset* o el entrenamiento de los modelos. Se asume que el lector tiene conocimientos de Python y está familiarizado con herramientas de desarrollo como Git y los entornos virtuales.

### D.2. Estructura de directorios

A continuación se muestra y explica la estructura de directorios del repositorio principal del proyecto, alojado en GitHub<sup>1</sup>.

```
/
└─ apks/
```

Directorio destinado a contener los archivos APK en bruto descargados para la creación del *dataset*. También almacena el catálogo de AndroZoo (`latest.csv`). Por su gran tamaño, el contenido de este directorio no se incluye en el repositorio de Git.

---

<sup>1</sup><https://github.com/dtx1007/TFG-Malware-Detection-Android>

/	
— dataset/	Directorio donde se colocarían los <i>datasets</i> procesados en formato <code>.csv</code> o <code>.pkl</code> , para ser utilizados por los cuadernos de entrenamiento. No se incluyen dentro del repositorio por motivos de tamaño pero se explica como generar el <i>dataset</i> propio más adelante.
— doc/	Alberga toda la documentación del proyecto, incluyendo la memoria y los anexos en formato <code>L<sup>A</sup>T<sub>E</sub>X</code> .
— model_artifacts/	Directorio donde se guardan todos los artefactos generados tras el entrenamiento: los modelos de red neuronal y clásicos, los vocabularios de características, los «escaladores» de normalización y las métricas de rendimiento.
— plots/	Contiene todas las gráficas generadas para el análisis de resultados y la interpretabilidad de los modelos.
— src/	El corazón del proyecto. Contiene todo el código fuente en Python y los <i>notebooks</i> de pruebas de Jupyter.

### D.3. Manual del programador

Esta sección está pensada como una guía de inicio rápido para un desarrollador. Se detallará la estructura del código fuente y se explicarán los flujos de trabajo más comunes, como la creación del *dataset* y el entrenamiento de los modelos.

Es importante destacar que este repositorio no incluye los *datasets* en bruto (APKs) ni los modelos ya entrenados debido a su gran tamaño. Para una demostración rápida con los modelos ya listos, se recomienda utilizar el [repositorio de despliegue](#). Esta guía está orientada a quien desee replicar el proceso desde cero.

#### Explicación del código fuente

Todo el código se encuentra en el directorio `src/`, organizado en subdirectorios con responsabilidades claras.

### Directorio `src/app`

Contiene todo el código de la aplicación web interactiva desarrollada con Streamlit.

```
app/  
├── malware_interpreter_app.py  
├── model_utils.py  
├── data_utils.py  
├── shap_utils.py  
└── ui_utils.py
```

- **malware\_interpreter\_app.py:** Es el punto de entrada de la aplicación web. Inicializa y controla la interfaz de usuario, gestiona el estado de la sesión (como el historial) y coordina las llamadas al resto de módulos para realizar el análisis cuando un usuario sube un APK.
- **model\_utils.py:** Encapsula la lógica de carga y uso de los modelos de IA. Contiene funciones para cargar los modelos (tanto para la red neuronal como para los modelos clásicos) desde disco usando un sistema de caché para optimizar el rendimiento, y para ejecutar las predicciones.
- **data\_utils.py:** Gestiona la carga de datos auxiliares necesarios para la aplicación, como el *dataset* de fondo que utiliza SHAP para sus explicaciones.
- **shap\_utils.py:** Centraliza la lógica de interpretabilidad. Contiene las funciones para crear el «explicador» de SHAP y para calcular los valores de importancia de las características para una predicción concreta.
- **ui\_utils.py:** Módulo con funciones de ayuda para generar componentes visuales específicos, como los gráficos de SHAP o la proyección UMAP.

### Directorio `src/notebooks`

Contiene los Jupyter Notebooks, que sirven a modo de «campo de pruebas» para el proyecto, se utilizan para la experimentación, el prototipado y el análisis de datos.

```
notebooks/  
├─ download_apks.ipynb  
├─ androguard_feature_extraction.ipynb  
├─ models_training.ipynb  
├─ model_intrepretability.ipynb  
├─ models_stats.ipynb  
├─ quantize_model.ipynb  
└─ hyperparameters_optimization.ipynb
```

- **download\_apks.ipynb:** Contiene el código para descargar los archivos APK desde AndroZoo, utilizando su catálogo para filtrar y seleccionar las muestras.
- **androguard\_feature\_extraction.ipynb:** Es uno de los cuadernos más importantes. Implementa el *pipeline* que toma los APKs descargados, los analiza con Androguard para extraer sus características estáticas y crea con ellas el *dataset* final.
- **models\_training.ipynb:** Contiene toda la lógica para entrenar y evaluar tanto la red neuronal como los modelos clásicos, utilizando la validación cruzada. Al finalizar, guarda los modelos y artefactos en disco.
- **model\_intrepretability.ipynb:** Se centra en la interpretabilidad. Carga los modelos ya entrenados y utiliza SHAP para generar los datos necesarios para las visualizaciones de diferentes gráficos como el de importancia de características, gráficos de fuerza, gráficos en cascada, etc.
- **models\_stats.ipynb:** Permite obtener una vista general del rendimiento de los modelos entrenados. Carga las métricas de todos los modelos entrenados y genera varios gráficos comparativos (boxplots, curvas ROC/PR, etc.).
- **quantize\_model.ipynb:** Cuaderno de pruebas para aplicar técnicas de cuantización al modelo de red neuronal y evaluar su impacto en el tamaño y el rendimiento.
- **hyperparameters\_optimization.ipynb:** Implementa el proceso de búsqueda de hiperparámetros óptimos utilizando la librería Optuna.

### Directorio `src/prototypes`

Este es el directorio más importante a nivel de código fuente. Contiene los módulos de Python que definen la arquitectura y la lógica de los modelos de IA.

```
prototypes/  
├── torch_apk_analysis_model.py  
├── torch_apk_analysis_model_io.py  
├── ml_model.py  
└── ml_model_io.py
```

- **torch\_apk\_analysis\_model.py:** Define la arquitectura completa de la red neuronal en PyTorch, incluyendo las clases para el `APKFeatureEmbedder`, el `APKClassifier` y el modelo principal que los une. También contiene las funciones para el bucle de entrenamiento, la evaluación y la inferencia.
- **torch\_apk\_analysis\_model\_io.py:** Gestiona el guardado y la carga del modelo de red neuronal y todos sus metadatos asociados (vocabularios, «escaladores», etc.).
- **ml\_model.py:** Define y entrena los modelos de aprendizaje automático clásicos (RandomForest, XGBoost, etc.) utilizando la librería `scikit-learn`.
- **ml\_model\_io.py:** Se encarga de guardar y cargar los modelos clásicos ya entrenados.

### Directorio `src/utils`

Contiene *scripts* con funciones de utilidad que dan soporte al resto del proyecto.

```
utils/  
├── feature_extraction.py  
├── preprocessing_utils.py  
└── vocab_utils.py
```

- **feature\_extraction.py:** Contiene la lógica del proceso de extracción de características con Androguard. Es utilizado por la aplicación web para analizar nuevas APKs.

- **preprocessing\_utils.py:** Contiene las funciones para preprocesar los datos extraídos (creación de vocabularios, *padding*, etc.), asegurando que el tratamiento de los datos sea consistente en todo el proyecto.
- **vocab\_utils.py:** Contiene funciones para la generación de los vocabularios empleados en el preprocesamiento.

## Guía de procesos comunes

A continuación se describen los pasos para ejecutar las tareas más comunes. Se asume que el entorno de desarrollo ya está configurado (ver sección [D.4](#)).

### Proceso de creación del *dataset*

1. **Obtener clave de API:** Es necesario solicitar una clave de API de AndroZoo<sup>2</sup>. Una vez obtenida, crear un archivo `.env` en la raíz del proyecto con el formato `ANDROZOO_API_KEY=tu_clave_aqui`.
2. **Descargar catálogo:** Descargar el catálogo actualizado de AndroZoo<sup>3</sup>, descomprimirlo y guardarlo en el directorio `apks/` con el nombre `latest.csv`.
3. **Descargar APKs:** Abrir el cuaderno `src/notebooks/download_apks.ipynb`. Configurar los parámetros al final del *notebook* (número de muestras, rutas de guardado) y ejecutarlo. El proceso comenzará a descargar las aplicaciones.
4. **Extraer características:** Abrir el cuaderno `src/notebooks/androguard_feature_extraction.ipynb`. Asegurarse de que las rutas de entrada coinciden con las del paso anterior y ejecutar la celda correspondiente para crear el *dataset*. El resultado se guardará por defecto en el directorio `dataset/`.

### Proceso de entrenamiento del modelo

Con el *dataset* ya creado, el entrenamiento se realiza desde el cuaderno `src/notebooks/models_training.ipynb`. Es importante configurar correctamente las celdas iniciales, especialmente el parámetro `load_fresh=True` la primera vez que se use un nuevo *dataset* para que se preprocese y se guarde

---

<sup>2</sup>Instrucciones de acceso disponibles en: <https://androzoo.uni.lu/access>

<sup>3</sup>Disponible en: <https://androzoo.uni.lu/static/lists/latest.csv.gz>

en disco una versión ya preprocesada. En ejecuciones posteriores, se puede poner en **False** para ahorrar tiempo. Tras configurar los hiperparámetros deseados, se puede ejecutar el cuaderno completo. Los modelos y artefactos resultantes se guardarán en el directorio `model_artifacts/`.

## D.4. Compilación, instalación y ejecución del proyecto

En esta sección se detallan los dos flujos principales para ejecutar el proyecto: uno para el desarrollo local y otro para el despliegue mediante Docker.

### Entorno de desarrollo (local)

Este es el flujo recomendado para modificar el código o entrenar nuevos modelos.

1. **Prerrequisitos:** Asegurarse de tener instalados Python 3.11+, Git, Git LFS y Poetry<sup>4</sup>.
2. **Clonar el repositorio:** Descargar el código fuente desde el repositorio principal.

```
# Clona el repositorio y descarga los modelos
git clone \
https://github.com/dtx1007/tfg_24_25
cd tfg_24_25
git lfs pull
```

```
# Construye la imagen (elegir una)
docker build -t streamlit-malware-app:cpu .
docker build --build-arg BUILD_TYPE=gpu -t \
streamlit-malware-app:gpu .
```

---

<sup>4</sup>Documentación oficial de Poetry: <https://python-poetry.org/docs/>

3. **Instalar dependencias:** Navegar a la raíz del proyecto en un terminal y ejecutar uno de los siguientes comandos:

```
# Para CPU
poetry install --extras=cpu
# Para GPU (con CUDA)
poetry install --extras=gpu
```

Poetry creará automáticamente un entorno virtual e instalará todos los paquetes necesarios. Se puede elegir la versión con o sin soporte para GPU. Es importante aclarar que, se ha de especificar uno de los extras o PyTorch no se instalará, impidiendo que se pueda ejecutar correctamente la aplicación o el resto de *scripts* y *notebooks*.

4. **Activar el entorno:** Ejecutar `poetry shell` para activar el entorno virtual. Una vez dentro, se pueden ejecutar todos los *scripts* y *notebooks* del proyecto.
5. **Desplegar aplicación en local (opcional):** Si se quisiera probar la aplicación en local solo haría falta ejecutar el siguiente comando:

```
streamlit run ./src/app/malware_interpreter_app.py
```

Si justo se ha descargado el repositorio la aplicación dará error al intentar acceder a ella puesto que no tendrá modelos que cargar, se han de entrenar primero (ver [D.3](#)).

## Entorno de despliegue (Docker)

Este método es el más sencillo para simplemente probar la aplicación final, ya que no requiere instalar dependencias manualmente. Se recomienda usar el «repositorio de despliegue»<sup>5</sup>.

1. **Requisitos previos:** Tener instalado Git, Git LFS y Docker.
2. **Clonación y construcción:** Clona el repositorio de despliegue y construye la imagen Docker.

---

<sup>5</sup>[https://github.com/dtx1007/streamlit\\_malware\\_detection\\_app](https://github.com/dtx1007/streamlit_malware_detection_app)



```
# Clona el repositorio y descarga los modelos
git clone ...
cd streamlit_malware_detection_app
git lfs pull

# Construye la imagen (elegir una)
docker build -t streamlit-malware-app:cpu .
docker build --build-arg BUILD_TYPE=gpu -t \
streamlit-malware-app:gpu .
```

3. **Ejecución:** Lanza el contenedor. La aplicación será accesible en <http://localhost:8501>.

```
# Ejecuta el contenedor (elegir una)
docker run --rm -p 8501:8501 \
streamlit-malware-app:cpu
docker run --rm --gpus all -p 8501:8501 \
streamlit-malware-app:gpu
```

## D.5. Pruebas del sistema

Es importante señalar que el proyecto no cuenta con una *suite* de pruebas automatizadas (como tests unitarios o de integración con *frameworks* como *pytest*). La metodología de *testing* se ha basado en un enfoque manual y exploratorio.

Los diferentes Jupyter Notebooks han servido como el principal entorno de pruebas para cada uno de los módulos. Cada cuaderno actúa como una prueba de concepto y de funcionamiento para la lógica que contiene: el cuaderno de extracción de características valida que el análisis con Androguard funciona, el de entrenamiento valida todo el *pipeline* de modelado, y así sucesivamente. Aunque este enfoque no sustituye a un sistema de pruebas automatizado, ha permitido validar cada componente de forma interactiva y asegurar que estos funcionan correctamente y que los resultados son correctos.



## Apéndice *E*

---

# Documentación de usuario

---

### E.1. Introducción

Este apéndice sirve como manual de usuario para la aplicación web de demostración desarrollada en el proyecto. El objetivo de este documento es guiar a cualquier persona, independientemente de su nivel técnico, a través del proceso de instalación y uso de la herramienta. Se explicará paso a paso cómo analizar una aplicación Android, cómo interpretar los resultados obtenidos y qué significa cada una de las visualizaciones que ofrece la interfaz, para que la experiencia sea lo más intuitiva posible.

### E.2. Requisitos de usuario

La aplicación ha sido empaquetada para que su ejecución sea lo más sencilla posible. Para poder utilizarla en un ordenador local, únicamente es necesario tener instaladas las siguientes herramientas de software:

- **Git:** Un sistema de control de versiones que se usará para descargar el código de la aplicación.
- **Git LFS (Large File Storage):** Una extensión de Git necesaria para descargar los archivos de los modelos de IA, que por su gran tamaño no se pueden gestionar de forma convencional.
- **Docker:** Una plataforma que permite ejecutar aplicaciones en entornos aislados llamados contenedores. Es la herramienta que nos permitirá lanzar la aplicación con un solo comando, sin preocuparnos por instalar Python ni ninguna de sus dependencias.

## E.3. Instalación

El método recomendado para ejecutar la aplicación es a través de Docker y utilizando el «repositorio de despliegue»<sup>1</sup>, que está específicamente preparado para ello. Para obtener información sobre cómo configurar un entorno de desarrollo local, consulte el Apéndice D.

Los pasos para el despliegue son los siguientes:

1. **Clonar el repositorio:** Abre una terminal o línea de comandos y ejecuta los siguientes comandos para descargar la aplicación y sus modelos.

```
# Clona el repositorio de despliegue
git clone \
https://github.com/dtx1007/streamlit_malware_detection_app
cd streamlit_malware_detection_app
```

```
# Descarga los archivos grandes (modelos) con Git LFS
git lfs pull
```

2. **Construir la imagen de Docker:** Una vez dentro del directorio, ejecuta el siguiente comando para que Docker construya la aplicación. Este paso puede tardar unos minutos la primera vez. Se recomienda usar la versión de CPU debido a su mayor compatibilidad.

```
# Construye la imagen para CPU
docker build -t streamlit-malware-app:cpu .
```

3. **Ejecutar la aplicación:** Finalmente, lanza la aplicación con el siguiente comando.

```
# Ejecuta el contenedor de la aplicación
docker run --rm -p 8501:8501 streamlit-malware-app:cpu
```

---

<sup>1</sup>Enlace al repositorio: [https://github.com/dtx1007/streamlit\\_malware\\_detection\\_app](https://github.com/dtx1007/streamlit_malware_detection_app)

Tras ejecutar el último comando, la aplicación estará en marcha. Puedes acceder a ella abriendo un navegador web y visitando la dirección: <http://localhost:8501>.

## E.4. Manual del usuario

Una vez que la aplicación está en ejecución, el usuario se encontrará con una interfaz interactiva diseñada para guiarlo a través del proceso de análisis.

### Página principal y análisis de una aplicación

Al entrar a la aplicación se nos muestra la página principal (Figura E.1). En la barra lateral izquierda se encuentra el «panel de control», desde donde se pueden subir aplicaciones para ser analizadas y se puede ver el historial de los análisis realizados durante la sesión, junto con un botón para limpiarlo. Para iniciar un análisis, simplemente hay que arrastrar y soltar un archivo o seleccionarlo con el botón «Browse files» y, una vez cargado, presionar «Analyze Uploaded APK».

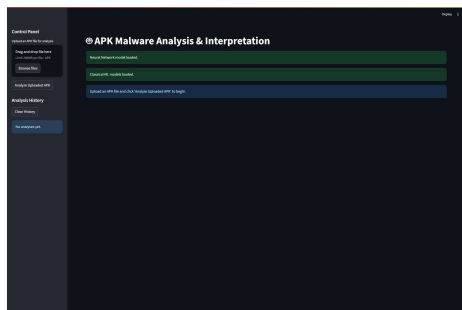


Figura E.1: Página principal de la aplicación antes de un análisis.




Figura E.2: Página de resumen tras realizar un análisis.

Tras unos segundos, la interfaz se actualizará para mostrar los resultados, organizados en varias pestañas. La pestaña inicial, «Summary» (Figura E.2), ofrece un resumen del veredicto final, indicando si el consenso de los modelos apunta a que la aplicación es maliciosa o benigna.

## Pestaña de predicciones

En esta pestaña (Figura E.3), se ofrece un desglose detallado de la predicción de cada uno de los modelos entrenados. Para cada modelo, se muestra la clase predicha («*Malware*» o «*Benign*») y el nivel de confianza que el modelo tiene en esa predicción, expresado como un porcentaje. Esto permite comparar el veredicto de los diferentes modelos.




Figura E.3: Pestaña de Predicciones con el detalle de cada modelo.

## Pestaña de las características extraídas

Esta sección ofrece total transparencia sobre la información que el sistema ha extraído de la APK para su análisis, permitiendo entender en qué datos se basan las predicciones. Se divide en varias subpestañas.

La primera, «AndroidManifest» (Figura E.4), muestra los componentes clave declarados en el manifiesto de la aplicación: los permisos que solicita (acceso a contactos, internet, etc.), las actividades (las diferentes «pantallas» que hay en la aplicación), los servicios (procesos en segundo plano) y los receptores (componentes que responden a eventos del sistema).

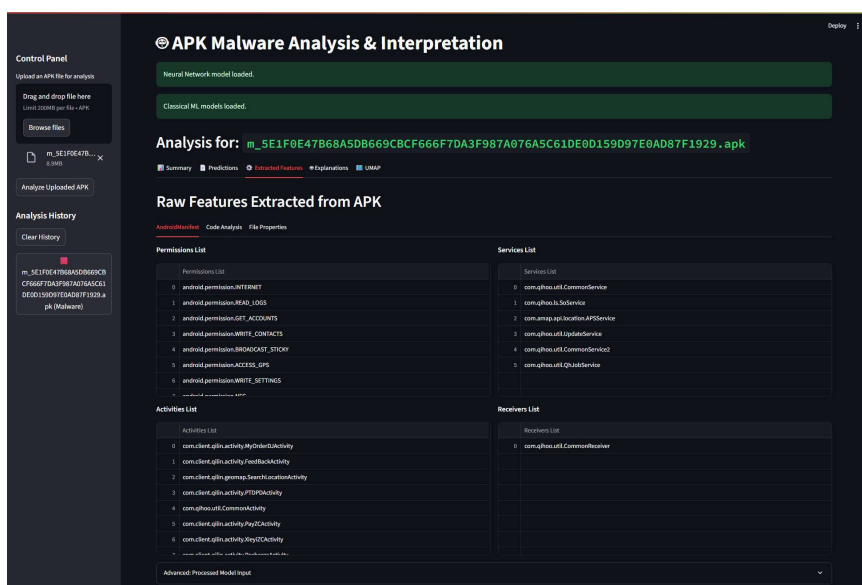


Figura E.4: Pestaña de características: Sección del AndroidManifest.

La subpestaña «Code Analysis» (Figura E.5) detalla las llamadas a la API, que son las funciones externas a la aplicación que esta usa, y el recuentos de los distintos *opcodes*, que son las instrucciones de bajo nivel que el sistema es capaz de ejecutar.




Figura E.5: Pestaña de características: Sección de análisis de código.

Control Panel

Upload an APK file for analysis

Drag and drop file here  
Limit 200MB per file • APK

Browse files

m\_5E1F0E47B...

3.8MB

Analyze Uploaded APK

Analyze History

Clear History

m\_5E1F0E47B68A5DB669C8CF666F7DA3F987A076A5C61DE0D159D97E0AD87F1929.apk (Malware)

APK Malware Analysis & Interpretation

Neural Network model loaded.

Classical ML models loaded.

Analysis for: m\_5E1F0E47B68A5DB669C8CF666F7DA3F987A076A5C61DE0D159D97E0AD87F1929.apk

Summary

Predictions

Extracted Features

Explanations

UNAP

Raw Features Extracted from APK

AndroidManifest

Code Analysis

File Properties

File Size (Bytes)

9,317,212

Fuzzy Hash (ssdeep)

qQjMaVqj1Uaks9FF1TYygfH922y1b/x1m6ZAn2akR/Rk2H2XXk13129/gfEGJuR

Advanced: Processed Model Input

Processed Data (Scaled & Tokenized)

	file_size	fuzzy_hash	activities_list																	services_list										receivers_list	perms		
0	1.391	57	31	30	22	41	62	57	6	35	41	51	59	14	19	20	69862	69860	69868	69873	37	69876	69887	69878	69885	66	32	58	73	132	54	29	9

Final Embeddings Fed to Classifier

	emb_0	emb_1	emb_2	emb_3	emb_4	emb_5	emb_6	emb_7	emb_8	emb_9	emb_10	emb_11	emb_12	emb_13	emb_14	emb_15	emb_16	emb_17	emb_18	emb_19	emb_20	emb_21	emb_22	emb_23
0	-0.278	-0.2354	0.0081	0.0322	-0.0793	-0.149	0.0368	0.0095	0.2272	0.0816	0.0499	0.0921	-0.0076	0.0681	-0.3213	0.2687	-0.1945	-0.1889	0.2637	-0.0288	0.1945	0.0304	-0.0161	0.0161

Figura E.6: Pestaña de características: Propiedades del archivo y datos procesados.



## Pestaña de explicaciones (interpretabilidad)

Esta es una de las pestañas más importantes, ya que intenta responder a la pregunta: «¿Por qué el modelo ha tomado esta decisión?». Utiliza la técnica SHAP para visualizar el razonamiento del modelo. Primero, se debe seleccionar en el menú desplegable el modelo que se desea analizar.

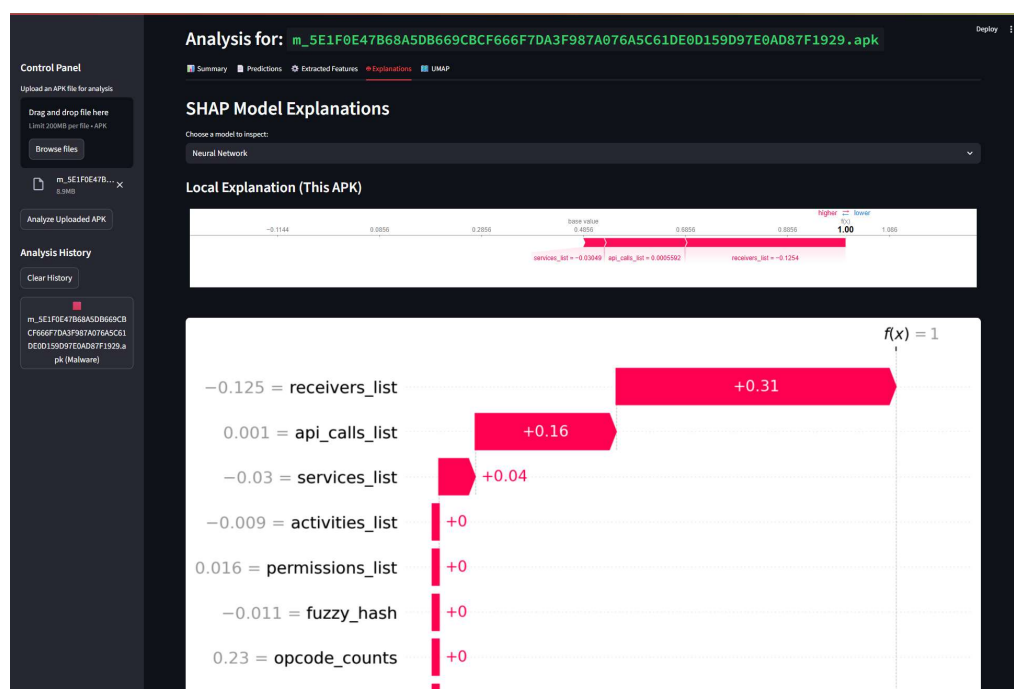


Figura E.7: Pestaña de explicaciones: Gráficos de interpretabilidad global del modelo.

La sección muestra primero el análisis local (Figura E.7), que se centra exclusivamente en la APK que se acaba de analizar. Hay dos gráficos en esta sección, el primero, llamado gráfico de «fuerzas» muestra el «tira y afloja» de las características: las que están en rojo han empujado la predicción hacia *malware*, mientras que las que están en azul han empujado hacia benigno. Por otro lado, el segundo de los gráficos, que se encuentra dejado del de «fuerzas» se llama gráfico en «cascada» y muestra exactamente la misma información pero de manera desglosada para que sea más sencillo entender qué ha influenciado más al modelo en realizar la predicción actual. Los valores de ambas gráficas se expresan en tanto por uno pero representan la «porción» de probabilidad de la predicción que han ayudado a conseguir.




Figura E.8: Pestaña de explicaciones: Gráfico de interpretabilidad local para la APK analizado.

A continuación, se muestra el análisis global (Figura E.8). Hay 3 gráficos en esta sección. El primero de ellos es un gráfico de barras, el cual representa la «importancia» absoluta (es independiente de la predicción) de las diferentes características de entrada del modelo y muestra de forma visual cuales son más importantes para este en términos general. El siguiente gráfico recibe el nombre de «enjambre» y muestra una vista más detallada del comportamiento del modelo: cada punto es una predicción y muestra cómo el valor de cada característica empuja la decisión hacia «malware» (valores SHAP positivos, hacia la derecha) o «benigno» (negativos, a la izquierda). Finalmente, está el «mapa de calor» el cual muestra cuales han sido las características más importantes para el modelo a la hora de realizar diferentes predicciones.

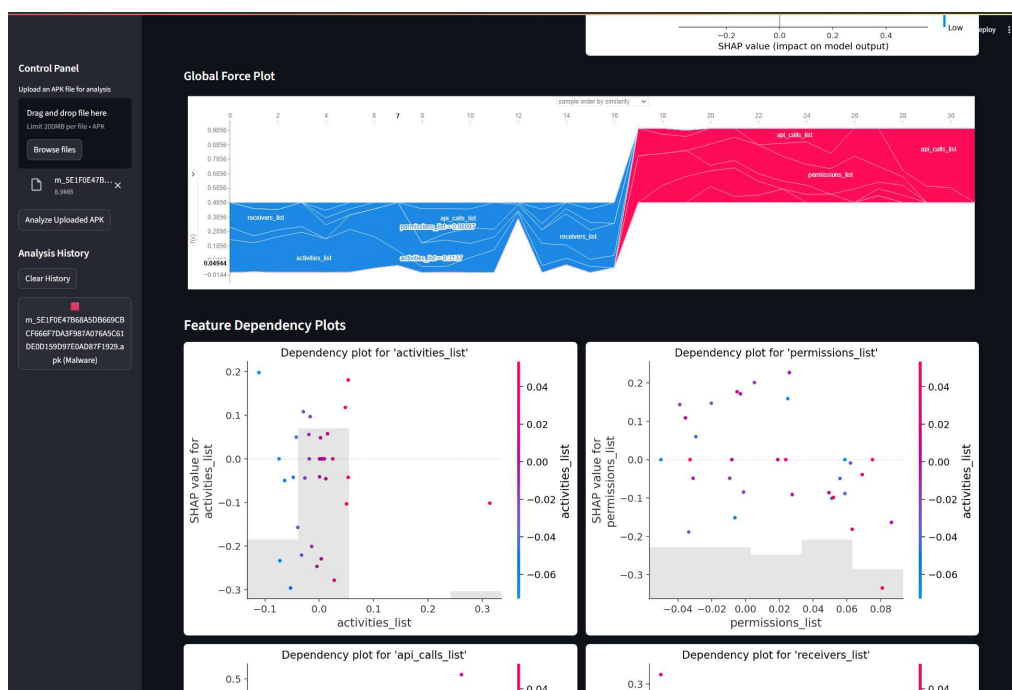


Figura E.9: Pestaña de explicaciones: Gráficos de dependencia de SHAP.

Por último, la Figura E.9 muestra un gráfico interactivo conocido como gráfico de «fuerzas» global, el cual se forma apilando todos los gráficos de «fuerzas» de todas las explicaciones de referencia. A su vez, se muestran los gráficos de «dependencia» de las características con mayor importancia para el modelo, contrastadas con la característica de mayor importancia, estos gráficos muestran el valor que tenía la característica dada respecto del valor de la predicción (valor SHAP), de tal manera se puede saber si para un valor dado de dicha característica la predicción suele ser «malware» o «benigna». A su vez, el color indica el valor que tenía la característica de contraste en esa predicción, esto ayuda a encontrar posibles interacciones entre las diferentes características.

## Pestaña de UMAP

Esta última pestaña (Figura E.10) ofrece una visualización acerca del espacio de *embeddings* del modelo. Es decir, representa de forma visual dónde cae la predicción dentro de su espacio de *embeddings*.




Figura E.10: Pestaña UMAP: Proyección 2D del espacio de *embeddings*.

Este gráfico muestra dónde se posiciona una aplicación dada dentro del espacio de «embeddings» del modelo, dicho de otra forma, a grandes rasgos, el modelo aprende a «agrupar» las aplicaciones maliciosas y separarlas de las aplicaciones benignas, este gráfico muestra precisamente dónde se colocó en este caso el modelo a la muestra actual.

## **Anexo de sostenibilización curricular**

---

### **F.1. Introducción**

Siguiendo las «Directrices para la introducción de la Sostenibilidad en el Curriculum» de la CRUE [1], este anexo presenta una reflexión personal sobre cómo el presente Trabajo de Fin de Grado se alinea con los principios de un desarrollo sostenible. Aunque a primera vista un proyecto de ciberseguridad y *software* pueda parecer alejado de los conceptos tradicionales de sostenibilidad, un análisis más profundo revela importantes conexiones con sus tres pilares fundamentales: el social, el ambiental y el económico.

El objetivo de este apartado es, por tanto, analizar el impacto del proyecto a través de estas tres dimensiones y reflexionar sobre cómo, a lo largo de su desarrollo, se han adquirido y aplicado de forma práctica algunas de las competencias transversales para la sostenibilidad que la universidad busca fomentar en sus titulados.

### **F.2. Impacto de la sostenibilidad en el proyecto**

La sostenibilidad, entendida de forma holística, busca un equilibrio entre la justicia social, la viabilidad económica y la calidad ambiental. Este proyecto, aunque de naturaleza técnica, tiene implicaciones en cada una de estas áreas.

### Dimensión social y ética

Este es, sin duda, el pilar donde el proyecto tiene su impacto más directo y significativo. El desarrollo de una herramienta para la detección de *malware* es, en esencia, un acto de protección social en el ecosistema digital. El *malware* no es solo una molestia técnica; es una herramienta que facilita el robo de datos personales, el fraude financiero, la violación de la privacidad y la desestabilización de las comunicaciones. Al crear un sistema que combate estas amenazas, el proyecto contribuye directamente a la construcción de un entorno digital más seguro y fiable para todos, un aspecto fundamental para la justicia social en la era en la que vivimos. Este enfoque se alinea con el principio ético de la sostenibilidad, que considera la protección y la seguridad de las personas como un objetivo primordial.

### Dimensión ambiental

La sostenibilidad ambiental en el ámbito del *software* está intrínsecamente ligada a la eficiencia energética y al uso de los recursos computacionales. En este sentido, la decisión de centrar el proyecto en el análisis estático en lugar del dinámico tiene una clara implicación ambiental. El análisis dinámico requiere la ejecución de aplicaciones en entornos controlados (*sandboxes*), que a menudo son máquinas virtuales que consumen una cantidad considerable de energía. El análisis estático, al no requerir ejecución, es un método inherentemente más eficiente y con una menor huella de carbono, especialmente si se piensa en su aplicación a gran escala.

Además, la conclusión final del proyecto, que aboga por un enfoque híbrido donde un *embedder* de red neuronal potencia a clasificadores clásicos mucho más ligeros, también tiene una vertiente de sostenibilidad. Un modelo como la Regresión Logística o XGBoost requiere muchos menos recursos computacionales para realizar una predicción que una red neuronal profunda completa. Esto significa que, si la herramienta se desplegara en millones de dispositivos, el consumo energético agregado sería significativamente menor, contribuyendo a la sostenibilidad del ecosistema digital.

### Dimensión económica

El impacto económico del *malware* es devastador, causando pérdidas millonarias cada año tanto a empresas como a particulares. Un sistema de detección eficaz como el que se ha desarrollado en este trabajo contribuye a la sostenibilidad económica al prevenir el fraude, proteger los activos digitales y reducir los costes asociados a la recuperación de ciberataques. Asimismo,

al tratarse de un proyecto desarrollado con herramientas de código abierto y con la intención de ser compartido bajo una licencia permisiva, se fomenta un modelo de innovación sostenible, donde el conocimiento y las herramientas se comparten para el beneficio de la comunidad, en lugar de permanecer en silos cerrados.

## F.3. Competencias de sostenibilidad adquiridas y aplicadas

El desarrollo de este proyecto también ha sido de gran utilidad para adquirir y poner en práctica las competencias transversales para la sostenibilidad definidas por la CRUE.

- **SOS1 - Contextualización crítica del conocimiento:** El proyecto no se limitó a resolver un problema técnico aislado. Fue necesario investigar y comprender la problemática social y económica del *malware* a nivel global, entendiendo cómo una solución tecnológica como esta interactúa con la sociedad y puede contribuir a mitigar un riesgo que afecta a millones de personas.
- **SOS2 - Utilización sostenible de recursos:** Esta competencia se aplicó directamente en la elección de la metodología. Se optó por el análisis estático por ser más eficiente en recursos que el dinámico. Además, todo el proceso de optimización del modelo, que culminó en la propuesta de un enfoque híbrido más ligero, fue un ejercicio práctico de búsqueda de la solución más eficiente y, por tanto, más sostenible.
- **SOS3 - Participación en procesos comunitarios:** Aunque es un proyecto individual, su desarrollo se ha enmarcado dentro de la comunidad del software de código abierto. Se han utilizado herramientas creadas por la comunidad (Androguard, PyTorch, etc.) y se ha construido sobre el conocimiento de la comunidad investigadora. La intención de licenciar el proyecto de forma abierta es una forma de devolver ese valor a la comunidad, promoviendo la sostenibilidad del conocimiento compartido.
- **SOS4 - Aplicación de principios éticos:** La ética ha sido un pilar central. El proyecto se enfoca en proteger a los usuarios, no en explotar datos. El método de análisis estático se eligió, entre otras cosas, porque respeta la privacidad al no requerir la ejecución de la aplicación ni el

acceso a los datos personales del usuario. Además, la inclusión de un módulo de interpretabilidad (SHAP) responde a la necesidad ética de que las decisiones de la IA sean transparentes y comprensibles, y no meras cajas negras".



---

## Bibliografía

---

- [1] crue.org. [https://www.crue.org/wp-content/uploads/2020/02/Directrices\\_Sostenibilidad\\_Crue2012.pdf](https://www.crue.org/wp-content/uploads/2020/02/Directrices_Sostenibilidad_Crue2012.pdf).
- [2] Forest - Stay focused, be present — forestapp.cc. <https://www.forestapp.cc/>. [Accessed 05-07-2025].
- [3] Seguridad Social: Cotización / Recaudación de Trabajadores — seg-social.es. <https://www.seg-social.es/wps/portal/wss/internet/Trabajadores/CotizacionRecaudacionTrabajadores/36537#36538>.
- [4] Kevin Allix, Tegawendé F. Bissyandé, Jacques Klein, and Yves Le Traon. Androzoo: Collecting millions of android apps for the research community. In *Proceedings of the 13th International Conference on Mining Software Repositories*, MSR '16, pages 468–471, New York, NY, USA, 2016. ACM.
- [5] Daniel Arp, Michael Spreitzenbarth, Malte Hubner, Hugo Gascon, Konrad Rieck, and CERT Siemens. Drebin: Effective and explainable detection of android malware in your pocket. In *Ndss*, volume 14, pages 23–26, 2014.
- [6] Kent Beck, Mike Beedle, Arie Van Bennekum, Alistair Cockburn, Ward Cunningham, Martin Fowler, James Grenning, Jim Highsmith, Andrew Hunt, Ron Jeffries, et al. Manifesto for agile software development. 2001.
- [7] Unión Europea. Directiva 2009/24/CE del parlamento europeo y el consejo, de 23 de abril de 2009, sobre la protección jurídica de programas de ordenador. *Diario Oficial de la Unión Europea L*, 111(5):16–22, 2009.

- [8] Mülhem İbrahim, Bayan Issa, and Muhammed Basheer Jasser. A method for automatic android malware detection based on static analysis and deep learning. *IEEE Access*, 10:117334–117352, 2022.